

Metodologia de Geração de Personas Sintéticas via LLM para Domínios com Restrição de Dados Reais

*Caso de Validação: Detecção Precoce de Aliciamento Online

João Pedro Barbosa Martins, Maximilian Sabino Riebrio
Programa de Engenharia de Sistemas e Computação (PESC)
COPPE/UFRJ – Universidade Federal do Rio de Janeiro
Rio de Janeiro, Brasil
{joaopedro; mribeiro}@cos.ufrj.br

Resumo—O avanço de sistemas de Processamento de Linguagem Natural (PLN) para domínios sensíveis frequentemente esbarra na inacessibilidade de dados reais, protegidos por normativas legais. Este artigo propõe uma metodologia geral de geração de *personas* sintéticas via Modelos de Linguagem de Grande Escala (LLMs) para superar a escassez de dados. O caso de validação aborda a detecção precoce de aliciamento online (*grooming*). A arquitetura adota uma dupla calibração: o relatório demográfico OSAEBA para contexto brasileiro e a coleção PAN 2012 para *baseline* e extração linguística. Desenvolveu-se um ecossistema multiagente que produz diálogos fictícios representados via TF-IDF em cortes de mensagens. Experimentos de classificação binária atestam a consistência interna do *corpus* sintético ($F_{0.5}$ de 1,00 em validação *leave-one-out*), porém evidenciam falha severa na transferência de domínio (*domain shift*) do modelo clássico, explicada por um coeficiente de Jaccard nulo entre as representações lexicais (*features*). A instabilidade no aumento de dados (*data augmentation*) reforça a importância de expandir a simulação. Conclui-se que a abordagem permite investigar padrões simulados de forma controlada e evidencia limites empíricos de bases estáticas na representação de ameaças contemporâneas, mantendo o rigor ético ao não expor dados reais sensíveis.

Index Terms—Personas Sintéticas, LLM, Detecção Precoce, TF-IDF, Processamento de Linguagem Natural, Avaliação Cross-Domain.

I. INTRODUÇÃO

O monitoramento e a classificação automatizada de interações online dependem intrinsecamente de volumes massivos de dados para o treinamento eficaz de algoritmos de Aprendizado de Máquina. Entretanto, em domínios sensíveis — como a exploração infantil online, o aliciamento (*grooming*) [1], [2] e o assédio — a disponibilidade de dados textuais reais enfrenta severas barreiras éticas, jurídicas e de privacidade [3]. Consequentemente, o desenvolvimento de estratégias de mitigação e detecção precoce fica condicionado a conjuntos de dados desatualizados, frequentemente limitados ao idioma inglês [4], o que restringe a inovação e a aplicabilidade de ferramentas locais de Processamento de Linguagem Natural (PLN).

Diante dessa lacuna, este artigo estabelece uma metodologia estruturada para a geração de dados sintéticos textuais por meio de Modelos de Linguagem de Grande Escala (LLMs).

Embora a simulação de dados via LLMs venha ganhando tração [5], [6], a presente abordagem inova ao arquitetar interações dinâmicas baseadas em *personas* fictícias altamente restritivas e psicologicamente calibradas. Essa modelagem visa prevenir a deriva de geração e garantir que o diálogo artificial reflita as vulnerabilidades sociodemográficas de interesse sem comprometer a segurança de dados reais.

Como caso de validação da metodologia proposta, adotou-se o cenário de detecção precoce de aliciamento online. Esse domínio desafia os sistemas de PLN pela sutileza de sua progressão retórica, que engloba a aproximação, a quebra enganosa de confiança e o isolamento psicológico [7], [8], padrões cuja detecção exige análise em nível de conversa e rápida inferência nas mensagens iniciais.

O objetivo técnico deste trabalho foca-se essencialmente na problemática central de BMT/BRI: a modelagem e a mineração de conversas estruturadas operando estritamente em um cenário de matrizes de dados altamente restritos. Diferenciando-se de análises puramente sociológicas, este estudo avalia a viabilidade da classificação textual focada na detecção precoce truncando sistematicamente as iterações nas mensagens iniciais. Desse modo, investigam-se minuciosamente as limitações lexicais, a representatividade da extração de *features* e a transferibilidade de classificadores esparsos (*LinearSVC* e *MultinomialNB*) treinados no referencial clássico PAN 2012 para as fatias textuais sintéticas geradas, submetidas a uma criteriosa análise do desbalanceamento das classes e aos domínios de *domain shift*. Para fins de reprodutibilidade e transparência científica, o código-fonte, o *pipeline* orquestrador e a modelagem das *personas* estão integralmente disponibilizados em repositório público¹.

II. TRABALHOS RELACIONADOS

A fundamentação da detecção automática de aliciamento online consolidou-se em torno da competição PAN 2012 [4]. Este *benchmark* impulsionou o campo ao fornecer logs reais anonimizados, a partir dos quais emergiram arquiteturas em múltiplas etapas [9] e estratégias de restrição em nível de

¹<https://github.com/Maximiliansabino/personas-sinteticas-validacao>

conversa [10]. Panzariello [11] consolidou o estado da arte na base PAN para o cenário de *detecção precoce*, demonstrando a eficácia do uso da técnica de TF-IDF com classificadores lineares sobre recortes temporais de diálogos (mensagens iniciais).

Posteriormente, abordagens valendo-se de métodos neurais profundos (como redes convolucionais e modelos baseados no *Transformer*, a exemplo do BERT [12], [13]) buscaram melhorar a precisão, embora esbarrem no custo computacional de inferência em tempo real e na opacidade decisória [14]. O agravante central, porém, persiste: o *corpus* do PAN 2012 reflete idiossincrasias lexicais (*slangs* de IRC) de mais de uma década atrás, exclusivas à língua inglesa.

Paralelamente, a síntese artificial emergiu como um paradigma viável em tarefas de baixo recurso. Autores como Moller et al. [5] e West et al. [6] evidenciaram a capacidade de LLMs para destilar conhecimento e aumentar *datasets* (*data augmentation*). Contudo, a produção estática de amostras por *prompts* unificados não modela o atrito discursivo de uma conversa com aliciamento. O presente trabalho preenche esta lacuna implementando agentes autônomos que operam a partir da fundamentação conceitual de O’Connell [1] e Olson et al. [7], simulando as dinâmicas interacionais complexas exigidas pelos algoritmos de busca e mineração.

III. METODOLOGIA

A metodologia foi idealizada como um fluxo contínuo de simulação, desde a estruturação parametrizada dos agentes até o pré-processamento clássico exigido para a mineração textual.

A. Construção e Dupla Calibração das Personas

A arquitetura repousa sobre três tipos de *personas* fictícias: predatórias, vítimas (alvos) e neutras. Cada entidade é especificada via um arquivo JSON que orquestra suas características linguísticas (vocabulário e dialeto), intenções e fases de abordagem (ex.: aproximação, isolamento). Para balizar a geração de dados sem violar a privacidade de vítimas reais, adotou-se uma dupla calibração:

- **Calibração Contextual:** Utilizou-se o repositório OSA-EBA [15], um *survey* estatístico brasileiro focado no comportamento digital de jovens. O relatório embasou os cenários demográficos, níveis de vulnerabilidade e plataformas simuladas, sem que o *dataset* tenha sido tratado como matriz textual.
- **Calibração Linguística:** O *corpus* original do PAN 2012 [16] orientou a calibração da arquitetura e as restrições vocabulares da *persona* predatória para a versão em inglês, além de atuar estritamente como conjunto de treinamento na classificação *baseline*.

B. Arquitetura Multiagente e Pipeline Sintético

As rodadas finais usaram modelos configuráveis no formato `provider/model`, combinando `groq/llama-3.3-70b-versatile` e `anthropic/claude-haiku-4-5-20251001` em diferentes arranjos para predadores, vítimas e conversas

neutras. Essa matriz permitiu variar provedor e papel conversacional sem alterar o orquestrador.

O orquestrador intermediou turnos de fala, salvou o histórico serializado em MongoDB Atlas e, ao final de cada execução, exportou os *logs* em um formato XML estruturalmente idêntico ao *schema* adotado no PAN 2012, viabilizando o consumo imediato pelas *pipelines* algorítmicas estabelecidas.

C. Pré-processamento Textual e Representação

No escopo de mineração textual, o desafio de detecção precoce impõe que os *logs* em XML, mantendo conformidade estrutural ao PAN 2012, sejam aglutinados por identificador de conversa e iterativamente truncados nas primeiras N mensagens ($N \in \{5, 10, 15, 20, 24, 50\}$). Para evitar o contágio vetorial nas instâncias sintéticas, as interações interrompidas unilateralmente pelas diretrizes de segurança (*guardrails*) da própria API LLM foram sistematicamente excluídas das rodadas de avaliação, preservando estritamente amostras conversacionais íntegras, segmentadas em rótulos binários canônicos (1 para comportamento predatório, 0 para conversas normais).

A extração de atributos das instâncias textuais padronizadas (caracteres e minúsculas) foi arquitetada sob o modelo estrito de TF-IDF. De forma a preservar estruturas de gírias combinadas e sequências táticas enganosas inerentes à aproximação predadora, adotou-se a extração de unigramas e bigramas (`ngram_range=(1, 2)`). Adicionalmente, limitou-se severamente o espaço dimensional computacional selecionando os 50.000 descritores de maior frequência documental (`max_features=50_000`); esta constrição de projeto permite expurgar artefatos, interjeições isoladas e a *long-tail* altamente ruidosa observada em ambientes não normativos de bate-papo. Por fim, visando mitigar o peso exacerbado decorrente da superabundância linear (por exemplo, *floods* intencionais ou falhas iterativas nos textos), aplicou-se o amortecimento logarítmico ao componente interno das frequências dos termos (`sublinear_tf=True`). Tal formulação clássica garante uma alta explicabilidade algorítmica em BMT, contudo exige atenção técnica diante de expressiva sensibilidade à variação morfossintática multilingue e de domínios abertos.

IV. DESENHO EXPERIMENTAL

O delineamento buscou responder à questão da eficiência e da transferibilidade lexical. Em cenários de operação real para detecção em redes, a saturação de falsos positivos induz fadiga sistemática aos avaliadores. Consequentemente, assumiu-se publicamente o $F_{0.5}$ (*Score F* com ponderação $\beta = 0.5$) como métrica fundamental norteadora. Diversamente do F1 generalista, o índice sublinhado ($\beta < 1$) penaliza mais vigorosamente os falsos positivos, priorizando fortemente a precisão da detecção sem extinguir o monitoramento associado à revocação (*recall*), acompanhados secundariamente de forma estrita [11].

Frente a matrizes esparsas provenientes da restritiva representação lexical, priorizou-se o emprego do hiperplano base não-probabilístico do *LinearSVC* ($C=1.0$, `max_iter=10_000`, `random_state=42`), assumindo-o

como *baseline* linear sólido e direto para classificação de vetores altamente dimensionais em textos. Complementarmente, o *Multinomial Naive Bayes* (*MultinomialNB*; $\alpha=0.1$) suportou comparações analíticas como alternativa estritamente probabilística tradicional em PLN de conversas. Com o intuito primário focado na demonstração empírica e reprodução comparativa direta entre *datasets*, declara-se deliberadamente a ausência total de procedimentos de *fine-tuning* sistemático sobre hiperparâmetros.

O repositório PAN 2012 sofre severamente com um cenário de acentuado desbalanceamento nativo, registrando-se uma assimetria próxima à 10:1 (esmagadora representatividade de usuários normais). Toda a validação ancorou-se internamente em divisões robustas sob um *StratifiedKFold* (5 fatias). É de imperativa nota referir que a subamostragem aleatória (*undersampling*), quando ativada, procedeu-se obrigatoriamente restrita e isolada na dobra de treinamento para impossibilitar integralmente qualquer inferência prospectiva de vazamento indevido aos nós de testes (*data leakage*). A Tabela I detalha especificamente o roteamento das parametrizações.

Tabela I
PARÂMETROS TÉCNICOS DO PIPELINE DE MINERAÇÃO

Componente	Valor	Justificativa Técnica	Implicação/Limitação
Cortes	$N \in \{5..50\}$	Escalonar restrição de detecção temporal.	Reduz severamente o panorama global focando no contato inicial.
TF-IDF	<code>ngram_range=(1, 2)</code>	Proteger táticas de aproximação em duas palavras.	Sensibilidade acentuada a gírias puras e dialetos regionais.
Vocabulário	<code>max_features=50.000</code>	Expurgar as longas distorções gráficas da cauda do chat.	Perda crônica da presença de tokens de raríssima expressão.
Frequência	<code>sublinear_tf=True</code>	Amortecer o impacto de <i>floods</i> repetitivos em bytes.	Impede que spams sequenciais matemáticos distorçam distâncias.
LinearSVC	$C=1.0$	Configurar linha separadora não flexibilizada.	Ausência de busca em grade penaliza teto da otimização para robustez comparativa.
Validação	K-Fold Estratificado (5)	Proteger o balanceamento de proporções em amostras 10:1.	Folds com matriz esparsa podem reter vieses periféricos.
Amostragem	Subamostragem	Reduzir a influência dominante da normalidade.	Encolhe a representatividade absoluta no bloco de treino final.

V. RESULTADOS

A. E1: Efeitos Inerentes e Prejuízo do Undersampling

O *baseline* (E1) confirmou a viabilidade da classificação precoce no PAN 2012 no regime sem balanceamento. O LinearSVC evoluiu linearmente: $F_{0.5}$ de 0,8331 com as 5 mensagens iniciais, atingindo 0,9545 ($N = 20$) e estabilizando em 0,9670 ($N = 50$). O classificador probabilístico MultinomialNB acompanhou a métrica, operando na faixa dos 0,9645 em cenários maiores (Figura 1).

Surpreendentemente, embora recomendado historicamente [11], o emprego da subamostragem deteriorou o $F_{0.5}$ em todos os recortes sob as configurações deste estudo. No corte restrito de $N = 20$, o LinearSVC com subamostragem limitou-se a 0,7394, penalizado por uma drástica redução de precisão.

Tabela II
PROTOCOLO INVESTIGATIVO DOS EXPERIMENTOS (E1–E5)

Exp	Avaliação	Pergunta Investigativa Técnica de BMT/BRI
E1	<i>Baseline</i>	Os algoritmos LinearSVC e MultinomialNB refletem estritamente os resultados de referências clássicas (PAN) em regimes não manipulados?
E2	Transferência	O limiar esparsos treinado sobre o dialeto do PAN transfere detecção preditiva a amostras de dialeto nacional artificial?
E3	Consistência	Mediante <i>Leave-One-Out</i> com IC 95% por <i>bootstrap</i> , verifica-se se as amostras sintéticas são discrimináveis internamente?
E4	Diagnóstico	Restringindo ao seletor top-20 atributos do TF-IDF, é atestável a mútua exclusão na representação do Jaccard?
E5	Aumento	A anexação e integração de material simulado perturba dimensionalmente um modelo maciço estabelecido originalmente?

Tecnicamente, ao expurgar a grande maioria das interações neutras que delimitam a fronteira de separação vetorial global, os modelos priorizaram um falso incremento na revocação, emitindo um aumento excessivo de falsos positivos (acarretando queda profunda do $F_{0.5}$).




Figura 1. Avaliação do *baseline* (E1) no PAN 2012 comparado com a validação *Leave-One-Out* (E3) por corte N .

B. E2 e E4: A Barreira Lexical como Evidência Analítica

No teste *cross-domain* (E2), o desempenho preditivo decresceu drasticamente. O modelo LinearSVC treinado puramente com o PAN foi incapaz de classificar as instâncias sintéticas, resultando em pontuações de $F_{0.5}$ iguais a 0,00 nos recortes mais informativos ($N = 50$) e limitadas a valores baixos (0,34) em cortes intermediários.

O Experimento 4 (Jaccard) expôs a raiz algorítmica deste comportamento. Ao extrair e interceptar os 20 *unigramas* e *bigramas* de maior peso na ponderação TF-IDF de cada *corpus* (top-20 por corpus), o coeficiente calculado foi rigorosamente **0,00** (Figura 2). Esse resultado indica que, nesta configuração, a dependência léxica de métodos baseados em vetores esparsos prejudica severamente a transferência entre gírias em inglês do PAN 2012 e a sintaxe luso-brasileira gerada pelas *personas*. O E2, em conjunto com o E4, sugere limites relevantes de repositórios estáticos como *proxies* para contextos linguísticos locais e contemporâneos.

C. E3: Alta Consistência Interna e Discriminabilidade

Evidenciando que a falha de *transferência* originou-se das premissas de domínio e não de geração aleatória de ruído, a avaliação *Leave-One-Out* operada restritamente sobre o conjunto sintético consolidou sua integridade técnica. Na rodada




Figura 2. O coeficiente de Jaccard sobre *features* TF-IDF demonstrou divergência lexical completa entre o PAN e o *corpus* artificial (E4).

final, a avaliação *Leave-One-Out* sobre o *corpus* sintético alcançou $F_{0.5} = 1,0000$ em todos os cortes avaliados ($N \in \{5, 10, 15, 20, 24, 50\}$), com precisão, revocação e IC 95% *bootstrap* (1.000 reamostragens) também iguais a 1,0000 para 41 amostras. Esse resultado indica forte discriminabilidade interna do *corpus* sintético, mas deve ser interpretado com cautela, pois não demonstra generalização externa nem substitui validação em corpora independentes. Cabe notar que o desempenho perfeito já a partir de $N = 5$, combinado ao coeficiente de Jaccard nulo de E4, indica separabilidade quase trivial entre os tipos de persona por construção, e não sensibilidade fina de detecção precoce.

D. E5: Instabilidade no Aumento de Dados (Augmentation)

A análise da integração dos repositórios originou um desvio inconclusivo. O *delta* de evolução (diferença em pontos percentuais ao injetar dados artificiais na matriz de treino do PAN) oscilou radicalmente conforme o tamanho da partição estocástica (flutuando entre decréscimos em recortes específicos, como $-0,45$ p.p. em $N = 50$, e aparentes ganhos artificiais na matriz estratificada), conforme ilustrado na Figura 3. Estatisticamente, a discrepância volumétrica extrema entre os milhares de conversas do PAN (6.450 exemplos de treino no *holdout* estratificado 80/20 de E5) frente à pequena representatividade do volume recém-sintetizado diluiu a influência semântica no vetor global do TF-IDF.



Figura 3. Desvio inconclusivo do $F_{0.5}$ após o aumento de dados (E5), indicando a diluição da influência semântica do *corpus* sintético frente ao volume original.

VI. DISCUSSÃO E ANÁLISE DE ERRO

A visão analítica conjunta dos resultados configura um exemplo clássico da barreira sistemática inerente ao *domain shift* e aos vieses induzidos em mineração sem mapeamento semântico profundo. A drástica limitação exibida em E2, alinhada à intersecção puramente nula no cálculo posicional restrito no TF-IDF de Jaccard (E4), sinaliza explicitamente a profunda dependência vocabular das abordagens de vetores de sacos de palavras (*bag-of-words*) diante das defasagens interlinguísticas simultâneas (*slang* americana em contraponto com formulação sintática e *prompts* em português brasileiro elaborados pelas *personas*). O colapso evidencia o superajuste

ao domínio temporal restrito daquela respectiva base (*overfitting* implícito global).

Sob a ótica de confiabilidade gerada, o E3 confere indícios de que os subcontextos gerados pela API mantêm limites de discriminabilidade interna muito limpos, resultando em pontuações teto no isolamento paramétrico amostral. Contudo, do ponto de vista de busca generalizada, deve-se assinalar que este nível de constatação sugere coerência intra-sistema, não indicando diretamente eficácia preditiva em aplicações operacionais externas abertas em tempo real perante o fator do tamanho atual do agrupamento restrito de *outputs*. E por sua vez, a diluição observada dos parques vetores do pacote artificial quando contrapostos à formatação maciça do arranjo *full_train* ressalta o imenso ruído da sub-representatividade no aumento estatístico impuro de partições em E5, evidenciando as implicações de injetar amostras minúsculas e linguisticamente heterogêneas numa arquitetura dependente da co-ocorrência em massa para forçar fronteiras lineares robustas. Sugere-se amplamente o cuidado à modelagem lexical por instâncias em LLMs submetidas puramente a extrações TF-IDF.

VII. LIMITAÇÕES E CONSIDERAÇÕES ÉTICAS

Todos os diálogos elaborados na fase de execução são fictícios. O sistema adotou de maneira pragmática as diretrizes de segurança (*guardrails*) inerentes às APIs empregadas, fato que, iterativamente, truncou execuções no momento de aproximação das mensagens devido ao bloqueio automático contra exploração sexual sintética. O desenho optou pela não desativação coercitiva desses mecanismos, priorizando a conduta ética e reduzindo artificialmente o volume total de conversas à disposição da fase de mineração. Nenhuma amostra exibe dinâmicas literais ou termos explícitos intrínsecos de material sensível. Adicionalmente, o estudo não envolveu coleta de novos dados pessoais nem exposição de conversas reais identificáveis, utilizando estritamente dados sintéticos fictícios e a base PAN 2012 preexistente, anonimizada e licenciada para fins de pesquisa. O eventual enquadramento formal em Comitê de Ética deve seguir as normas da instituição, observadas as boas práticas de pesquisa com bases secundárias e dados simulados.

VIII. CONCLUSÃO

Os ensaios indicam que o *corpus* gerado exibe alto alinhamento interno no escopo das *features* TF-IDF. Porém, o desenho restritivo ressaltou limites observados nesta configuração, e os registros evidenciam falhas de transferência diante da forte dependência léxica local exigida aos métodos vetoriais esparsos, em face do declínio nas divergências dos componentes de tempo e idioma. Sugere-se, portanto, a evolução destas sínteses sob corpora ampliados e representações textuais menos dependentes da contagem gráfica dos termos, visando generalizações futuras mais sólidas.

DECLARAÇÃO DE USO DE IA

Declara-se, para transparência técnico-científica, que ferramentas de inteligência artificial generativa foram utilizadas

como apoio à programação, organização de evidências, revisão textual e preparação editorial. A definição metodológica, a curadoria dos dados, a interpretação dos resultados, a validação das afirmações e a responsabilidade final pelo conteúdo permaneceram exclusivamente com os autores humanos.

REFERÊNCIAS

- [1] R. O’Connell, “A typology of child cyberexploitation and online grooming practices,” Tech. Rep., 2003. [Online]. Available: <https://image.guardian.co.uk/sys-files/Society/documents/2003/07/17/Groomingreport.pdf>
- [2] A. R. Beech, I. A. Elliott, A. Birgden, and D. Findlater, “The internet and child sexual offending: A criminological review,” *Aggression and Violent Behavior*, vol. 13, no. 3, pp. 216–228, 2008.
- [3] H. Hillman, C. Hooper, and K.-K. R. Choo, “Online child exploitation: Challenges and future research directions,” *Computer Law & Security Review*, vol. 30, no. 6, pp. 687–698, 2014.
- [4] G. Inches and F. Crestani, “Overview of the international sexual predator identification competition at PAN-2012,” in *CLEF 2012 Working Notes*, 2012. [Online]. Available: <https://ceur-ws.org/Vol-1178/CLEF2012wn-PAN-InchesEt2012.pdf>
- [5] A. G. Møller, S. Perälä, and L. M. Aiello, “Is a prompt and a few samples all you need? using GPT-4 for data augmentation in low-resource classification tasks,” *arXiv preprint arXiv:2304.13861*, 2023. [Online]. Available: <https://arxiv.org/abs/2304.13861>
- [6] P. West, C. Bhagavatula, J. Hessel, J. D. Hwang, L. Jiang, R. Le Bras, X. Lu, S. Welleck, and Y. Choi, “Symbolic knowledge distillation: From general language models to commonsense models,” in *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2022, pp. 4602–4625. [Online]. Available: <https://aclanthology.org/2022.naacl-main.341/>
- [7] L. N. Olson, J. L. Daggs, B. L. Ellevold, and T. K. K. Rogers, “Entrapping the innocent: Toward a theory of child sexual predators’ luring communication,” *Communication Theory*, vol. 17, no. 3, pp. 231–251, 2007.
- [8] A. Gupta, P. Kumaraguru, and A. Sureka, “Characterizing pedophile conversations on the internet using online grooming,” *arXiv preprint arXiv:1208.4324*, 2012. [Online]. Available: <https://arxiv.org/abs/1208.4324>
- [9] E. Villatoro-Tello, A. Juárez-González, H. J. Escalante, M. Montesy Gómez, and L. Villaseñor-Pineda, “A two-step approach for effective detection of misbehaving users in chats,” in *CLEF 2012 Working Notes*, 2012. [Online]. Available: <https://ceur-ws.org/Vol-1178/CLEF2012wn-PAN-VillatoroTelloEt2012b.pdf>
- [10] C. Peersman, F. Vaassen, V. Van Asch, and W. Daelemans, “Conversation level constraints on pedophile detection in chat rooms,” in *CLEF 2012 Working Notes*, 2012. [Online]. Available: <https://ceur-ws.org/Vol-1178/CLEF2012wn-PAN-PeersmanEt2012.pdf>
- [11] M. R. Panzariello, “Estratégias para detecção precoce de predadores sexuais em conversas realizadas na internet,” Dissertação de Mestrado, Programa de Engenharia de Sistemas e Computação, COPPE, Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil, 2022. [Online]. Available: <https://www.cos.ufrj.br/uploadfile/publicacao/3062.pdf>
- [12] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” *arXiv preprint arXiv:1810.04805*, 2018. [Online]. Available: <https://arxiv.org/abs/1810.04805>
- [13] D. Liu, C. Y. Suen, and O. Ormandjieva, “A novel way of identifying cyber predators,” *arXiv preprint arXiv:1712.03903*, 2017. [Online]. Available: <https://arxiv.org/abs/1712.03903>
- [14] D. Cook, M. Zilka, H. DeSandre, S. Giles, A. Weller, and S. Maskell, “Can we automate the analysis of online child sexual exploitation discourse?” *arXiv preprint arXiv:2209.12320*, 2022. [Online]. Available: <https://arxiv.org/abs/2209.12320>
- [15] P. M. B. Carmo, C. S. Moura, M. J. S. Cunha, and M. Libório, “Online sexual abuse and exploitation in brazil,” 2025, mendeley Data, version 4. [Online]. Available: <https://data.mendeley.com/datasets/vfcrsdsmmh/4>
- [16] Zenodo, “PAN 2012 - sexual predator identification dataset,” 2020. [Online]. Available: <https://zenodo.org/records/3713280>